

# 两种基于神经网络的故障诊断方法

陈如清

(嘉兴学院信息工程学院, 浙江省 嘉兴市 314001)

## COMPARISON BETWEEN TWO FAULT DIAGNOSIS METHODS BASED ON NEURAL NETWORK

CHEN Ru-qing

(School of Information Engineering, Jiaxing University, Jiaxing 314001, Zhejiang Province, China)

**ABSTRACT:** Neural network (NN) is often used to construct a fault mapping for the fault diagnosis of a complex equipment or system. Because there are some problems existing in the normal neural networks such as the long training time and dilemma of stability, a fault diagnosis method based on recurrent neural network (RNN) with deviation error units is presented by taking the forced draught fan as research object. 8 fault characteristic parameters are extracted after the logic processing of the signals from the detection system. 8 common fault patterns are used as fault samples to train the BP NN and the RNN, much comparison and analysis is carried out between the two networks in simulation result and training process. It is shown that the RNN diagnosis approach is better than BP NN method in converging speed, accuracy and stability. It can satisfy the practical need of an on-line fault diagnosis system.

**KEY WORDS:** Thermal power engineering; On-line fault diagnosis; BP neural network; RNN; Fault pattern

**摘要:** 复杂设备或系统的故障诊断中常采用神经网络构建故障映射关系, 针对实际应用中神经网络存在收敛速度慢、学习记忆不稳定等不足, 以一电站锅炉送风机为诊断对象研究了基于带有偏差单元的递归神经网络故障诊断方法。对状态检测系统采集的信号进行逻辑处理, 分离出 8 个故障特征参数。以 8 种常见故障模式作为 BP 网络和递归神经网络的训练样本, 对训练过程和仿真结果作了对比分析, 结果表明该诊断方法在收敛速度、精度和稳定性能等方面均有良好改善, 满足了系统在线故障诊断的需求。

**关键词:** 热能动力工程; 在线故障诊断; BP 网络; 递归神经网络; 故障模式

### 1 引言

现代工业生产中, 随着机械设备自动化程度的

提高, 对设备的在线故障监测与诊断故障诊断技术提出了更高要求。传统诊断方法(如冗余法或普通模式识别方法)在系统或设备的故障诊断中发挥了很好的作用, 但随着诊断对象的日趋庞大和复杂, 故障特征与故障状态之间呈现强的非线性, 单一的识别方法很难识别各种故障状态。有必要探索其他故障诊断方法。

人工神经网络技术在近 20 年内发展迅速, 凭借其良好的并行处理能力、自适应能力及联想记忆能力解决了很多挑战性的工程实际问题<sup>[1-4]</sup>。用于故障诊断能改善常规故障诊断方法, 解决多维空间模式或非线性模式的识别问题, 适合于对多故障、多征兆这类复杂对象的故障诊断<sup>[5-6]</sup>。此外, 常用的电机故障诊断方法也为神经网络诊断方法的研究提供了很好的借鉴<sup>[7-11]</sup>。本文结合实际问题对常用的 BP 神经网络故障诊断方法进行了分析, 针对其收敛速度慢、学习记忆不稳定等不足设计了一种带有偏差单元的递归神经网络故障诊断方法, 对比及验证结果表明该方法克服了现有方法的不足, 取得了满意的应用效果。

### 2 BP 神经网络故障诊断方法

故障诊断过程是一个典型的模式分类问题, 将特征空间向量映射到故障空间。故障诊断的模型可以用三元函数  $(A_S, F_S, Y)$  来表示。其中  $A_S = \{A_0, \dots, A_i, \dots, A_n\}$  为描述系统早期故障的症状的  $n$  维特征空间向量,  $A_i$  为描述某一故障特征的参数或属性。  $F_S = \{F_0, \dots, F_j, \dots, F_m\}$  为故障集合, 包含有限个具体的系统故障状态。  $Y$  为故障映射关系,  $A_S$ 、 $F_S$  分别为其定义域和值域。故障诊断问题的实质就是

寻找一种未知的故障映射关系。基于神经网络的故障诊断方法是用具体神经网络（如 BP 网络等）来构建故障映射关系<sup>[2]</sup>。

常见的 BP 网络主要有 3 层，即输入层、隐层和输出层组成。输入层接收各故障信息，单元个数代表故障特征参数的个数。隐层根据输入层提供的信息进行内部学习和处理，将收敛后各节点的阈值和网络的连接权值保存下来。当诊断的故障模式确定时可采取有导师学习方式，对于每一种故障样本的输入都有一个具体输出故障状态与之对应。输出层输出具体故障类型。BP 算法是常用的网络训练算法，但存在收敛速度慢等缺点<sup>[4,12]</sup>，又有一些改进的算法如加  $g$  因子法和模拟退火法等，一定程度上改善了其性能。但当故障模式分类界限不明显时其收敛速度仍然很慢，不能保证收敛到最小点，达不到实时故障诊断要求。

研究表明，在机械设备故障诊断中，机械振动信号较为敏感地反映各种故障状态。提取故障特征时可将振动信号进行频谱分析以分离出振动信号的主要频率部分，将不同振动频率下的振幅值作为故障特征量<sup>[13]</sup>。表 1 为通过对某电站锅炉送风机状态检测系统采集的振动摩擦信号进行谱分析，归一化处理后得到的各种典型故障(包括电动机转子断条、轴承故障、转子不平衡和不对中等 8 种常见故障)的谱分布表，其中  $f$  为电源频率，各故障特征参数值为相应故障下的特征频率。用 BP 神经网络进行故障诊断，网络的输入层单元数为 8，对应 8 维故障特征参数，输出层的 8 节点为具体故障编码，故障时相应的输出单元值为“1”，其余为“0”，中间层通过调整最终选取 9 个单元。权值和阈值修正按照文献[3]中所采用的 Rumelhart 等提出的改进的最快下降法<sup>[3]</sup>，训练 31420 次后误差为 0.0021，诊断结果证明该方法有效。文献[12]采用了 BP 旋转算法对神经网络训练，有效克服了传统 BP 算法的假饱和现象，使训练次数大大减少，收敛速度可达到传统方法的 10 倍<sup>[12]</sup>。

表 1 实际故障样本

Tab. 1 The virtual fault samples

故障类型	故障特征参数值							
	$<0.4f$	$0.41\sim0.49f$	$0.5f$	$0.51\sim0.59f$	$1f$	$2f$	$3\sim5f$	高频段
1	0.00	0.00	0.00	0.00	1.00	0.00	0.00	0.00
2	0.00	0.00	0.00	0.00	0.40	0.20	0.20	0.20
3	0.00	0.00	0.00	0.00	0.90	0.05	0.05	0.00
4	0.00	0.00	0.00	0.00	0.40	0.60	0.00	0.00
5	0.40	0.40	0.00	0.10	0.00	0.00	0.00	0.10
6	0.10	0.10	0.00	0.10	0.20	0.10	0.20	0.20
7	0.10	0.20	0.00	0.00	0.00	0.80	0.00	0.20
8	0.00	0.00	0.00	0.00	0.00	1.00	0.00	0.00

### 3 带有偏差单元的递归神经网络故障诊断方法

在 BP 网络的基础上加入反馈信号及偏差单元构成内部回归神经网络(IRN)，根据反馈途径不同可构成 Jordan 和 Elman 型两种不同的 IRN 模型，本文所采用的神经网络结构是在 Jordan 和 Elman 网络结构基础上的一种带有偏差单元的 IRN 网络模型。带有偏差单元的 IRN 网络可如下描述<sup>[14]</sup>：

$$Y(h) = \sum_{j=1}^{N_2} W_{O,j} B_j(h) + a \cdot W_{O,bias} \quad (1)$$

$$B_j(h) = f(S_j(h)) \quad (2)$$

$$S_j(h) = \sum_{i=1}^{N_1} W_{R,ij} B_i(h-1) + \sum_{i=1}^{N_1} W_{I,ij} X_i(h) + b \cdot W_{I,j,bias} \quad (3)$$

式中  $X_i(h)$  和  $B_j(h)$  是分别为在时间  $h$  的第  $i$  个输入和第  $j$  个隐层节点的输出， $B_i(h-1)$  是在时间  $(h-1)$  的第  $i$  个隐层节点的输出，为其上一步的延时输出。 $Y_1(h) \sim Y_{N_3}(h)$  是带有偏差单元的 RNN 的输出向量； $W_I, W_R, W_O$  分别为从输入层到隐含层、回归信号、从隐含层到输出层的权系数； $W_{I,bias}$ 、 $W_{O,bias}$  分别为加在隐含层和输出层上的偏差单元的权系数； $f(\cdot)$  为隐含层的非线性激活函数，本文选用 sigmoid 函数； $a$ 、 $b$  分别为网络中预先设定的输出层和隐含层的偏差值。

如图 1 所示，隐层节点不仅接收来自输入层的信号，还接收自身的延迟输出信号，其输出可视作动态系统的状态，即接收新信息同时也存储过去输入输出信息。带有偏差单元的 RNN 同三层 BP 网




图 1 带有偏差单元的递归神经网络拓扑结构图

Fig. 1 Topology structure graph of RNN with deviation error units

络类似,当偏差节点和关联节点为0时就是BP网络,权系数调整规则借用BP算法,各联接权的调整量分别与各学习模式对的误差函数 $E_k$ 成比例地变化,相对于全局误差函数 $E$ 的联接权调整是在所有学习模式全部提供给网络之后统一进行,即累计误差逆传播算法<sup>[7,12]</sup>。

对表1所列出的送风机故障采用带偏差单元的递归神经网络进行故障诊断。RNN整个学习过程为:①初始化网络,确定各层单元数,给权值和阈值赋初值并选取各层权值的学习速度。根据本故障模式特点构建神经网络,输入、输出层单元数均选取8个,分别对应8个故障特征参数和8位故障编码。隐层单元数的选取需经过反复调整比较,结果表明单元数为12时效果最佳。训练过程中选取输出层权值的学习速度 $a=0.46$ ,隐含层权值的学习速度 $b=0.8$ ,递归层权值的学习速度 $v=1.5$ ,输出偏差单元的学习速度 $r=3995$ ,输入偏差单元的学习速度 $w=28$ , $a=0.039$ , $b=0.036$ 。②将表1的8组故障特征参数值作为故障模式提供给RNN,对应的8组8位故障编码作为网络输出。③按输入输出模式计算隐层和输出层的输入输出值及其一般化误差,再调整隐层到输出层及输入层到隐层之间的连接权值。这样完成对一个故障模式训练。④重新选取下一个故障样本,重复以上训练过程直到8组样本训练结束。

表2 典型故障样本的实际输出与理想输出

Tab. 2 The virtual output and excepted output of the fault samples

序号	实际输出								理想输出							
1	0.9997	0.0000	0.0000	0.0000	0.0000	0.0001	0.0001	0.0001	1	0	0	0	0	0	0	0
2	0.0000	0.9992	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0	1	0	0	0	0	0	0
3	0.0000	0.0000	1.0000	0.0000	0.0000	0.0001	0.0000	0.0001	0	0	1	0	0	0	0	0
4	0.0001	0.0000	0.0000	0.9995	0.0000	0.0001	0.0001	0.0001	0	0	0	1	0	0	0	0
5	0.0001	0.0000	0.0001	0.0000	0.9999	0.0001	0.0001	0.0001	0	0	0	0	1	0	0	0
6	0.0000	0.0000	0.0000	0.0000	0.0000	0.9998	0.0000	0.0001	0	0	0	0	0	1	0	0
7	0.0001	0.0000	0.0000	0.0000	0.0000	0.0001	0.9993	0.0001	0	0	0	0	0	0	1	0
8	0.0000	0.0000	0.0000	0.0000	0.0000	0.0001	0.0001	0.9998	0	0	0	0	0	0	0	1

## 4 结论

本文对送风机状态检测系统采集的数据进行逻辑处理得到典型故障样本,用两种不同神经网络建立故障特征与诊断结果之间的映射关系。分析对比表明:

(1) 本文所采取的带有偏差单元的递归神经网络能有效克服实际运用中BP网络存在的问题,具有收敛速度快、精度高,稳定性好等特点。对于训练后的BP网络,当出现新的学习模式时将更新已有的连接权值导致原记忆的学习模式信息消失。而RNN网络则在样本学习训练时将原学习样本和

⑤从8组样本中随机选取一组故障模式计算隐含层和输出层的输入、输出值及其一般化误差,再进行各连接权值调整,直到全局误差小于设定值为止。

按上述过程对RNN训练,当训练到第4步,精度达到 $8.1385 \times 10^{-4}$ ,接近于零,完全满足实时诊断要求。训练误差曲线图2所示,网络的实际输出如表2所示。




图2 训练误差曲线

Fig. 2 Training error curve of RNN

将采用本方法所设计的诊断系统用于实际设备在线故障诊断,实验结果表明在故障情况下网络输出的故障编码能准确指示设备故障状态,如发生电机转子断条和转动部分松动故障时,网络的输出故障编码分别为“0.9996 0.0000 0.0001 0.0000 0.0000 0.0002 0.0001 0.0000”和“0.0001 0.0003 0.0000 0.0000 0.9998 0.0001 0.0002 0.0001”,与分析结果相符。

新的学习模式一起重新进行训练,使网络的学习记忆具有良好的稳定性。

(2) 仿真和实验结果表明,采用带有偏差单元的递归神经网络故障诊断方法提高了故障诊断效率,改善了现有神经网络故障诊断方法,适合于复杂设备或系统的实时故障诊断。

(3) 具有良好的扩展性。当故障模式增多时采用该神经网络进行故障诊断仍然适合。笔者曾对某电力电子设备的115种故障模式进行分类定位,通过选取适当的网络参数训练故障样本,当训练到第10步,其精度可达到0.022,满足该设备实际诊断要求。

## 参考文献

- [1] Timo Sorsa, Neikkin Koivo. Application of artificial neural network in process fault diagnosis [J]. Automatica, 1993, 29(4): 843-849.
- [2] Jia-Zhou He, Zhi-Hua Zhou, Xu-Ri Yin *et al.* Using neural networks for fault diagnosis[C]. Proceedings of the IEEE-INNS-ENNS international joint conference on neural networks, Como, Italy, 2000(5): 217-220.
- [3] 黄晓光, 王永泓, 翁史烈. 基于 BP 算法的电站燃气轮机故障诊断 [J]. 中国电机工程学报, 2000, 20(12): 72-74.  
Huang Xiaoguang, Wang Yonghong, Weng Shilie. Gas turbine fault diagnosis based on the BP algorithm[J]. Proceedings of the CSEE, 2000, 20(12): 72-74.
- [4] 原培新, 徐玉秀, 刘恩东. Powell 法与 BP 法训练人工神经网络效果之比较[J]. 中国电机工程学报, 2002, 22(2): 103-106.  
Yuan Peixin, Xu Yuxiu, Liu Endong. Comparison between powell algorithm and BP algorithm in training neural network [J]. Proceedings of the CSEE, 2002, 22(2): 103-106.
- [5] 何耀华, 韩守木, 程尚模. 基于多神经网络协同推理的故障诊断系统的研制[J]. 中国电机工程学报, 1999, 19(12): 57-60.  
He Yaohua, Han Shoumu, Cheng Shangmo. Development of fault diagnosis system based on multineural network jointed inference [J]. Proceedings of the CSEE, 1999, 19(12): 57-60.
- [6] 陈长征, 栗青, 刘一芳, 等. 汽轮发电机组故障智能诊断方法研究 [J]. 中国电机工程学报, 2002, 22(5): 121-124.  
Chen Changzheng, Li Qing, Liu Yifang *et al.* Intelligent fault diagnosis method for turbo-generator unit[J]. Proceedings of the CSEE, 2002, 22(5): 121-124.
- [7] 王善永, 陆颂元, 马元奎, 等. 汽轮发电机组转子动静碰摩故障检测的小波分析方法研究[J]. 中国电机工程学报, 1999, 19(3): 1-5.  
Wang Shanyong, Lu Songyuan, Ma Yuankui *et al.* Application of wavelets to turbogenerator unit for impace fault detection [J]. Proceedings of the CSEE, 1999, 19(3): 1-5.
- [8] 陈耀武, 汪乐宇. 转子机械故障诊断仪器系统[J]. 中国电机工程学报, 2000, 20(12): 47-51.  
Chen Yaowu, Wang Leyu. A novel rotor faults diagnosis instrument [J]. Proceedings of the CSEE, 2000, 20(12): 47-51.
- [9] 王立欣, 王明彦, 齐明. 电机故障的逻辑诊断方法[J]. 中国电机工程学报, 2003, 23(3): 112-115.  
Wang Lixin, Wang Mingyan, Qi Ming. Logical fault diagnosis method of electrical machine[J]. Proceedings of the CSEE, 2003, 23(3): 112-115.
- [10] 刘振兴, 尹项根, 张哲. 基于 Hilbert 模量频谱分析的异步电动机转子故障在线监测与诊断方法[J]. 中国电机工程学报, 2003, 23(7): 158-161.  
Liu Zhenxing, Yin Xianggen, Zhang Zhe. Online monitoring and diagnosis way based on spectrum analysis of Hilbert modulus in induction motors[J]. Proceedings of the CSEE, 2003, 23(7): 158-161.
- [11] 冷永刚, 王太勇, 李瑞欣, 等. 变尺度随机共振用于电机故障的监测诊断[J]. 中国电机工程学报, 2003, 23(11): 111-115.  
Leng Yonggang, Wang Taiyong, Li Ruixin *et al.* Scale transformation stochastic for the monitoring and diagnosis of electromotor faults [J]. Proceedings of the CSEE, 2003, 23(11): 111-115.
- [12] 张定会. BP 旋转算法在故障诊断中的应用[J]. 计算机应用, 2003, 23(12): 197-199.  
Zhang Dinghui. Fault diagnosis based on BP eddy arithmetic [J]. Computer Application, 2003, 23(12): 197-199.
- [13] 胡芑庆, 温熙森. 转子碰摩故障振动特征的数值分析与辨识方法 [J]. 中国电机工程学报, 2002, 22(12): 70-73.  
Hu Niaoqing, Wen Xisen. Analysis and identification methods for vibration haracteristics of rotor rub-impact fault[J]. Proceedings of the CSEE, 2002, 22(12): 70-73.
- [14] 闻新, 周露, 王丹力, 等. Matlab 神经网络应用设计[M]. 北京: 科学出版社, 2000.

收稿日期: 2005-02-10。

作者简介:

陈如清 (1979-), 男, 江西萍乡人, 硕士, 研究方向为模式识别及其在故障诊断中的应用等。